

Исследовательский отчет

“Артефакты и паттерны генеративного ИИ для статического анализа”

ЧАСТЬ 1. ИЗОБРАЖЕНИЯ (Midjourney, DALL-E, Stable Diffusion)

1. Как это работает

Большинство современных генераторов картинок работают на базе диффузионных моделей (Diffusion Models). Процесс начинается с «белого шума» (случайного набора пикселей). Модель пошагово «вычитает» этот шум, ориентируясь на математическое представление текстового промпта (embeddings), пока не сформирует осмысленное изображение.

2. За что зацепиться статическому анализатору:

А. Стандарты метаданных и криптографические вотермарки (C2PA)

В ответ на указ Джо Байдена об ИИ (октябрь 2023 г.) и законы ЕС (AI Act), индустрия начала внедрять стандарты маркировки. Главный из них сейчас — C2PA (Coalition for Content Provenance and Authenticity). Что это: Это криптографически подписанные метаданные, вшитые в заголовок файла (JPEG/PNG/WebP). Они содержат историю создания файла.

Кто использует: OpenAI (DALL-E 3), Microsoft (Bing Image Creator), Adobe (Firefly). Midjourney планирует внедрение.

Как анализировать статически: Искать в бинарном коде (hex) файла маркеры JUMBF (JPEG Universal Metadata Box Format) или парсить EXIF/XMP данные. Если в поле Software или в c2pa.credentials есть подписи OpenAI/Adobe — это ИИ.

Б. Водяные знаки на уровне пикселей (SynthID)

Google (Imagen 2/3) использует технологию SynthID.

Что это: Невидимый водяной знак, который не хранится в метаданных. Он изменяет частотные характеристики пикселей (работает в вейвлет-области изображения).

Как анализировать: Обычный статический анализ текста/hex здесь бессилён, требуется прогон через математический фильтр (например, преобразование Фурье - FFT). На спектрограмме Фурье ИИ-изображения часто оставляют четкие сетчатые паттерны (grid artifacts), которых не бывает у реальных фотографий.

В. Бинарные артефакты (EXIF и заголовки)

Отсутствие данных матрицы камеры: В настоящих фото всегда есть EXIF-данные (модель камеры, выдержка, фокусное расстояние, ISO). ИИ-генераторы либо удаляют EXIF полностью (Midjourney часто выдает "чистый" PNG), либо оставляют специфичные пустые поля. ICC Профили: ИИ-картинки часто имеют стандартизированные, идеально чистые цветовые профили (sRGB IEC61966-2.1), в то время как камеры прописывают свои специфические профили производителей.

Г. Специфичные названия файлов

Пользователи часто скачивают картинки и заливают их на сайты как есть:

Midjourney: username_prompt_text_hash.png (например: ivan_a_cat_in_space_8b9a2c.png).

DALL-E: DALL·E 2023-11-05 14.23.11 - prompt.png (очень характерный паттерн с датой и словом DALL·E).

Stable Diffusion (WebUI): 00012-123456789.png (порядковый номер + seed генерации).

ЧАСТЬ 2. ВИДЕО (Sora, Runway Gen-2, Pika, Kling)

1. Как это работает

Синтез видео — это эволюция диффузионных моделей. Модель генерирует не просто пиксели (пространство), но и их изменение во времени (spatio-temporal diffusion).

2. За что зацепиться:

А. Метаданные контейнера (MP4/WebM)

Как и в изображениях, C2PA сейчас внедряется в видеоконтейнеры. Анализ MP4 атомов: Видеофайлы MP4 состоят из блоков (атомов/боксов). C2PA вшивается в специальные боксы (обычно внутри атома moov или uuid). Статический анализатор может парсить дерево атомов MP4 и искать криптографические подписи генераторов.

Б.Arteфакты кодирования (GOP и макроблоки)

Реальная камера сжимает видео аппаратно (H.264/H.265), создавая специфическое распределение I-кадров, P-кадров и B-кадров (Group of Pictures - GOP).

ИИ-модели часто генерируют сырые кадры, которые потом программно сжимаются ffmpeg перед отдачей пользователю.

Структура макроблоков и матриц квантования у ИИ-видео будет "слишком идеальной" или соответствовать дефолтным настройкам ffmpeg, в отличие от артефактов матрицы реальной камеры.

В. Метаданные аудиодорожки

Большинство генераторов видео (Runway, Sora) генерируют только визуальный ряд.

Статический маркер: Видеофайл вообще не содержит аудиопотока (отсутствует аудио-трек в контейнере). Реальные видео с телефонов/камер в 99% случаев имеют хотя бы пустую или шумовую аудиодорожку.

ЧАСТЬ 3. ТЕКСТ (ChatGPT, Claude, Gemini)

1. Как это работает

Большие языковые модели (LLM) — это авторегрессионные трансформеры. Они не "думают", а вычисляют вероятность следующего токена (слога/слова) на основе предыдущего контекста. Поэтому тексты ИИ математически "усреднены".

2. За что зацепиться статическому анализатору:

А. Криптографические вотермарки (Схема Ааронсона)

Скотт Ааронсон (исследователь OpenAI) разработал метод вотермаркинга текста.

Принцип: Модель при выборе синонимов использует псевдослучайный генератор (PRNG), ключ к которому есть у OpenAI. Из-за этого распределение слов в тексте подчиняется определенному математическому закону.

Анализ: Без ключа OpenAI 100% подтвердить это сложно, но можно измерить Perplexity (непредсказуемость текста) и Burstiness (разброс длины и сложности предложений). ИИ пишет с низкой Perplexity (очень предсказуемо) и низкой Burstiness (предложения одинаковой длины). Регулярные выражения и счетчики длин слов/предложений могут дать скоринг вероятности ИИ.

Б. Скрытые и невидимые символы (Zero-Width Characters)

Некоторые платформы (и сторонние обертки над API) внедряют вотермарки физически.

Что искать (Regex):

\u200B (Zero-width space)

\u200C (Zero-width non-joiner)

\u200D (Zero-width joiner)

\uFEFF (Zero-width no-break space)

Паттерны этих символов могут кодировать бинарные данные (id аккаунта, факт генерации).

В. Лексические паттерны и маркеры (Самое простое для статического анализа)

ИИ использует специфический словарь и структуру. Ваш статический анализатор может использовать списки стоп-слов и регулярные выражения:

Слова-маркеры (особенно в английском): Delve, tapestry, testament, crucial, underscore, realm, beacon, landscape, multifaceted, it's important to note. (Слово delve стало мемом, так как ChatGPT использует его в 1000 раз чаще, чем люди).

В русском: Важно отметить, в заключение, этот аспект подчеркивает, многогранный, безусловно.

Ошибки промптинга (Грязный копипаст):

As an AI language model... / Как языковая модель ИИ...

I cannot fulfill this request... / Я не могу выполнить этот запрос...

Here is the article you requested: / Вот статья по вашему запросу:

Структурные паттерны Markdown: ИИ обожает оборачивать термины в ****жирный шрифт**** и делать списки там, где человек написал бы просто текстом. Чрезмерное использование структур разметки — сильный статический сигнал.

ИТОГ: База для вашего статического анализатора

Чтобы реализовать задачу в коде, вам нужно создать систему модулей (пайплайн). Вот конкретный чек-лист проверок, которые можно реализовать скриптами (например, на Python/Java):

Модуль анализа файлов (Фото/Видео):

- Проверка хеша имени файла: Regex на паттерны Midjourney, DALL-E, Stable Diffusion.
- Hex/Метаданные: Поиск подстрок c2pa, JUMBF, OpenAI, Adobe Standard в бинарнике файла.
- EXIF-анализ: Оценка "пустоты" EXIF данных. Если фото выглядит как снятое на камеру, но не имеет тегов линзы/матрицы — подозрение на ИИ.
- Контейнер видео: Проверка наличия аудиодорожки (отсутствие = подозрение).

Модуль анализа текста:

- Очистка и поиск невидимок: Поиск Unicode zero-width символов.
- Словарь ИИ-маркеров: Regex поиск типичных фраз "Как ИИ...", "Важно отметить", "delve" и т.д.
- Структурный анализатор: Подсчет дисперсии длины предложений (чем она меньше, тем вероятнее ИИ). Подсчет количества элементов списков Markdown на тысячу знаков.
- N-gram анализ (опционально): Статистический анализ частотности сочетаний слов по сравнению с корпусом текстов, написанных человеком.

Этот подход позволит вам отсеивать до 70-80% сырого, не отредактированного ИИ-контента чисто статическими методами, не прибегая к ресурсоемким ML-моделям.